# AI 情绪系统 · 补充教程

> Wave 14：心情融合、科学衰减与实时响应

---

## 这是什么

这份文档是《给 AI 搭建一个情绪系统：完整教程》的补充。原教程搭建了三层情绪模型（词典 + 心情池 + 事件流）和心情闭环。这份补充解决原教程未覆盖的三个问题：

- 装饰心情和评分心情是割裂的两条管道，角色回复不反映日常活动
- PA/NA 的时间衰减用指数函数，不符合人类遗忘规律
- 评分是 30 分钟批处理，角色被骂了要等半小时才会难过

---

## 一、统一心情融合

### 1.1 问题

原系统中，装饰心情（角色日常波动）和评分心情（对话后 PANAS 评分）走两条独立管道。装饰心情只影响"刚才在做的事"的文字描述，不参与 PA/NA 数值计算。评分心情有自己的 PA/NA 累计逻辑。两者各管各的。

结果：角色的装饰心情显示"遛完狗"（开心），但评分心情说"担心焦虑"（负面），角色行为只受评分心情影响，完全无视装饰心情——像一个人嘴上说着开心的事，但表情完全没反应。

### 1.2 解决方案

把装饰心情和评分心情合并到同一个事件池，用同一个衰减公式、同一个 PA/NA 计算循环处理。装饰心情的 PA/NA 贡献从 V/A 推导：

```
pa += max(0, V) × A × 0.5 × w
na += max(0, -V) × A × 0.5 × w
```

× 0.5 是量纲对齐系数：pa_delta 范围 ±0.5，V×A 范围 0~1，乘 0.5 后量级一致。

这样做之后，Rutledge et al. (2014) 的设计原则得到体现——所有事件用同一个衰减因子，不按类型区分权重。事件自身的属性（重要性、唤醒度）自然决定影响力。

### 1.3 情绪胶囊联动

前端的情绪胶囊（显示角色当前心情的标签）改为取统一事件池中最新的一条，不管是装饰心情还是评分心情。哪个更新就显示哪个。对话后如果触发了评分且产生了新的 mood_log，胶囊就会从"遛完狗（舒畅）"变成"失落"——实时反映角色状态。

---

## 二、幂律衰减替代指数衰减

### 2.1 为什么换

原系统用指数衰减 `exp(-t/12)`，半衰期约 8.3 小时。Wixted & Ebbesen (1991, *Psychological Science*) 的研究证明，人类遗忘曲线的形式是**幂律**而非指数：

```
R(t) = a · t^(-b)
```

Wixted (2004, *Annual Review of Psychology*) 的综述进一步验证：幂律在所有实验条件下（人类词汇回忆、面孔识别、动物延迟匹配）都优于线性、指数、指数幂、双曲线和对数五种替代方案。

幂律的直觉：短期内衰减很快，但长期衰减速度变慢。不像指数那样均匀消失——重要的事虽然也会淡化，但永远不会完全归零。

### 2.2 重要性调节衰减速率

Verduyn & Lavrijsen (2015, *Motivation and Emotion*) 研究了 27 种情绪的持续时间，发现事件重要性是预测情绪持续时间最一致的评估维度（r = 0.59, p = 0.001）。

衰减指数 b 由重要性调节：

```
b_eff = b_base / (1 + importance / 10)
```

importance=1（日常小事）→ b_eff ≈ 0.64，衰减快。importance=9（重大事件）→ b_eff ≈ 0.37，衰减慢。

### 2.3 正负情绪不对称衰减（FAB）

Walker & Skowronski (2009) 的 Fading Affect Bias 研究发现：正面事件关联的情绪强度消退速度比负面事件慢；初始强度越高的事件越不容易消退。

正面情绪的衰减指数额外乘一个减速因子：

```
if (valence > 0) b_eff *= 0.85  // 正面情绪衰减慢 15%
```

### 2.4 最终公式

```
w(t) = (1 + t/τ)^(-b_eff)
```

| 参数 | 值 | 来源 |
| --- | --- | --- |
| τ（时间尺度） | 4 小时 | Verduyn 2015，日常情绪中位持续 2-3h |
| b_base（基础衰减指数） | 0.7 | Wixted 典型 b 值范围 0.2-1.0 中偏高位 |
| FAB 系数 | 0.85 | Walker & Skowronski 2009 |

### 2.5 效果预览

| 时间 | 日常小事 (imp=1) | 重要事件 (imp=5) | 极端事件 (imp=9) |
| --- | --- | --- | --- |
| 1 小时 | 83% | 89% | 91% |
| 4 小时 | 62% | 72% | 76% |
| 12 小时 | 38% | 51% | 57% |
| 24 小时 | 26% | 39% | 46% |
| 48 小时 | 18% | 30% | 36% |

---

## 三、PA/NA 软互抑（ESM）

### 3.1 问题

PA 和 NA 是 PANAS 的两个独立维度，理论上可以同时高。但实际测试中出现 PA=1.0 NA=1.0 的极端情况——角色同时极度开心又极度难过，行为指令矛盾。

### 3.2 解决方案

Cacioppo & Berntson (1994) 的 Evaluative Space Model (ESM) 提出 PA 和 NA 有四种运行模式：互抑（reciprocal，最常见）、共激活（coactivation，少见）、解耦、共抑制。Larsen et al. (2001) 的实验数据显示，仅约 10% 的被试能同时感到极度快乐和极度悲伤，且这种状态不稳定。

在 PA/NA clamp（0~1）之后，加一步软互抑：

```
pa_final = pa × (1 - k × na)
na_final = na × (1 - k × pa)
```

k = 0.3。允许轻度共存（bittersweet），但防止极端同高。

---

# 四、对话历史时间标记

## 4.1 问题

角色看到的对话历史（通常最近 30 条消息）是"扁平"的——一天前的吵架和五分钟前的撒娇在上下文窗口里权重相同。角色没有时间感。

## 4.2 解决方案

两层同时做：

- **算法层**：幂律衰减（第二节）从数值上降低旧事件的心情权重
- **信息层**：在对话历史中插入时间分隔符，让 LLM 直接看到时间流逝

SQL 查询加 `created_at` 字段。消息间隔 ≥ 1 小时时插入标记：

```
[系统提示：以上对话发生在 14 小时前。以下是更近的对话。]
```

同时在行为指令末尾加上下文时间感指令，告诉角色"不要让旧对话的情绪覆盖你当前的心理状态"。

两层不是替代关系，是互补——算法从数值上降低旧事件影响，时间标记从认知上帮 LLM 正确理解情景。

---

# 五、实时情绪响应

## 5.1 问题

心情快照在对话开始前计算，对话过程中不更新。角色 PA=0.9（很开心），用户突然说"我不要你了"——角色应该瞬间受伤，但 prompt 还在说"你现在很开心"，两个信号打架。

## 5.2 解决方案

在行为指令末尾加一条优先级规则：

> 预设心情是背景色，用户当前这条消息才是前景——前景优先。

如果用户当前消息带有伤害/愤怒/拒绝，角色必须对这条消息做出真实反应，即使之前心情很好。反过来，低落的角色被说暖话也可以被融化。

---

## 六、心情闭环补充：情绪漏斗与完整数据流

原教程阶段 5 建立了心情闭环的基本结构。本节补充两个关键改进：评分触发机制（何时评分）和完整的数据流串联。

### 6.1 完整数据流

每轮对话的完整链路，7 个步骤形成闭环：

```
① 构建心情快照
   统一事件池（装饰+评分）→ 幂律衰减 → ESM 互抑 → PA/NA
                    ↓
② 心情注入 prompt
   行为指令 + 实时覆盖规则 + 对话历史时间标记
                    ↓
③ LLM 生成回复 → 返回用户
                    ↓
④ 本地情绪漏斗扫描用户消息
   词典 ~20000 词，追踪 minV/maxV/avgV，零 API 调用
                    ↓
⑤ 评分路由
   ├─ 大波动 → 立即评分（评分 LLM ~500 token）
   └─ 小波动 → 标记脏位，等 30 分钟批处理
   └─ 没有对话 → 不评分，不消耗 token
                    ↓
⑥ 评分写入
   结果写入 ambient 层 → PA/NA 更新 → 胶囊更新
                    ↓
⑦ 下次对话回到①，角色行为反映新心情 → 闭环 ✅
```

**步骤详解：**

**① 构建心情快照** — 从统一事件池（装饰心情 + 评分心情合并）读取所有心情事件，按幂律衰减计算权重，加权累计 PA/NA，经 ESM 软互抑修正后输出角色当前情绪状态。这是角色进入对话前的"背景情绪"。

**② 心情注入 prompt** — 将心情快照转为自然语言行为指令，注入 system prompt。包含三层信息：行为基调（PA/NA 决定）、装饰心情（"刚才在做的事"）、实时覆盖规则（"用户当前这条消息比预设心情优先"）。对话历史中插入时间分隔符，让角色知道哪些是旧对话。

**③ LLM 生成回复** — 角色基于注入的心情状态 + 对话历史生成回复，返回用户。回复自然带上心

情色彩，不主动点破。

**④ 本地情绪漏斗** — 回复完成后，对用户消息做本地情绪扫描。启动时加载情感词典（~20000 词）到内存 Map，扫描时做子串匹配，追踪 avgV（平均效价）、minV（最极端负面词）、maxV（最极端正面词）、negCount（负面词数量）。全程零 API 调用。

**⑤ 评分路由** — 根据漏斗结果决定走哪条路：

- 大波动（触发条件命中）→ 立即调用评分 LLM（约 500 token）
- 小波动（条件未命中）→ 标记脏位，等 30 分钟批处理
- 没有对话 → 不评分，不消耗 token

**⑥ 评分写入** — 评分结果（PA/NA delta + 情感词 + V/A）写入 ambient 层。情绪胶囊取统一事件池中最新的一条更新显示。

**⑦ 闭环** — 下次对话回到步骤①，心情快照读到新的评分数据，角色行为自然反映更新后的情绪。

### 6.2 漏斗触发条件

漏斗的核心问题：什么程度的情绪变化算"大波动"，值得消耗 token 立即评分？

参考 Kuppens & Verduyn (2017) 的情绪动态学框架，情绪不稳定性用 MSSD（Mean Squared Successive Difference）衡量——关注连续情绪变化的幅度。ESM（经验取样）研究中，健康被试的情绪个体内标准差约 0.11-0.17（归一化到 0-1 后）。据此：

- V 变化 > 0.2 ≈ 1 个标准差，是有意义的情绪变化
- V 变化 > 0.5 ≈ 跨越 Russell 象限边界，是大变化

| 条件 | 阈值依据 | 说明 |
| --- | --- | --- |
| minV < -0.5 | 跨象限（V>0.5） | 单个强负面词即触发（如"讨厌" V≈-0.7） |
| negCount ≥ 2 且 avgV < -0.2 | ≥1 SD | 两个中等负面词累积 |
| intensity ≥ 0.7 | 词密度+标点 | 感叹号/问号密集 |
| PA≥0.5 且 avgV<-0.2 | MSSD 落差 | 角色开心但消息负面 |
| NA≥0.4 且 avgV>0.2 | MSSD 反转 | 角色低落但消息正面 |
| maxV > 0.7 | 跨象限 | 强正面词也触发 |
| 命中 urgentPhrases | 口语兜底 | 词典覆盖不到的短语 |

扫描函数追踪 minV 和 maxV（最极端的词），而非仅计数。基于 Houben et al. (2015) 元分析

（793 效应量，N=11,381）：情绪不稳定性的度量应关注变化幅度，而非简单频次。

---

# 七、评分模型选型

## 7.1 核心发现

评分任务（判断对话情绪、给 PA/NA 分数）不需要强模型。准确度主要由词典锚定决定。

## 7.2 无词典 vs 有词典

| 条件 | PA 平均偏差 | NA 平均偏差 | 方向错误 |
|---|---|---|---|
| 无词典 prompt | 0.200 | 不稳定 | “说重话”场景最便宜模型评反（pa=+0.25） |
| 有词典 prompt | 0.050 | 0.025 | 无，全部方向一致 |

加词典后，最便宜的模型（$0.30/百万 token）跟贵 5 倍的模型偏差仅 0.05——远低于感知阈值。

> 词典占评分准确度的 ~70%，模型占 ~30%。好的词典 + 弱模型 ≈ 无词典 + 强模型。

## 7.3 裸模型 V/A 准确度对比

用 8 个有学术标注 V/A 值的词做 ground truth 测试：

| 模型 | V 偏差 | A 偏差 | 总偏差 |
|---|---|---|---|
| DeepSeek V3 | 0.241 | 0.139 | 0.380 |
| Qwen-Turbo | 0.347 | 0.167 | 0.514 |

裸模型 DeepSeek 更准。但加上词典 + 校准锚点后差距被抹平。微小偏差可视为”角色个性”——不是每个人对同一件事的情绪反应都一模一样。

## 7.4 推荐架构

```
评分请求 → 主力模型（最便宜，+ 词典锚定）
    ├─ 成功 → 写入评分
    └─ 失败 → 备用模型（fallback）
        └─ 也失败 → 记录 both_fail，跳过
```

评分触发方式：本地情绪漏斗检测到大波动时立即评分（0 额外 token），否则等 30 分钟批处

理。日常对话不额外消耗 token，只有情绪转折点才调用评分 LLM。

---

## 八、调参指南

| 现象 | 调什么 | 怎么调 |
| --- | --- | --- |
| 正面偏移太强（PA 总封顶） | FAB 系数 | 0.85 → 0.90 |
| 衰减太快（角色太快忘事） | τ | 4 → 6 |
| 衰减太慢（旧事影响太久） | τ | 4 → 3 |
| 互抑太强（情绪太平淡） | ESM k | 0.3 → 0.2 |
| 互抑太弱（PA/NA 又同高） | ESM k | 0.3 → 0.4 |
| 情绪漏斗太灵敏（频繁评分费 token） | negCount 阈值 | 2 → 3，或 minV 从 -0.5 到 -0.6 |
| 情绪漏斗太迟钝（说重话没反应） | minV 阈值 | -0.5 → -0.4，或扩充 urgentPhrases |

---

## 九、学术引用


1. **Kuppens, P. & Verduyn, P.** (2017). Emotion dynamics. *Current Opinion in Psychology*, 17, 22-26. — 情绪动态学框架（变异性/不稳定性/惯性）
2. **Houben, M. et al.** (2015). The relation between short-term emotion dynamics and psychological well-being: A meta-analysis. *Psychological Bulletin*, 141(4), 901-930. — 793效应量元分析，MSSD定义
3. **Jahng, S. et al.** (2008). Analysis of affective instability in EMA. *Psychological Methods*, 13(4), 354-375. — MSSD作为情感不稳定性度量
4. **Wixted, J.T. & Ebbesen, E.B.** (1991). On the form of forgetting. *Psychological Science*, 2(6), 409-415. — 遗忘曲线幂律形式
5. **Wixted, J.T.** (2004). The psychology and neuroscience of forgetting. *Annual Review of Psychology*, 55, 235-269. — 幂律衰减综述
6. **Verduyn, P. & Lavrijsen, S.** (2015). Which emotions last longest and why. *Motivation and Emotion*, 39(1), 119-127. — 重要性调节持续时间
7. **Brans, K. & Verduyn, P.** (2014). Intensity and duration of negative emotions. *PLOS*

*ONE*. — 评估与调节预测情绪

8. **Walker, W.R. & Skowronski, J.J.** (2009). The fading affect bias. *Applied Cognitive Psychology*. — 正负情绪衰减不对称
9. **Cacioppo, J.T. & Berntson, G.G.** (1994). Relationship between attitudes and evaluative space. *Psychological Review*. — ESM 互抑模型
10. **Larsen, J.T. et al.** (2001). Can people feel happy and sad at the same time? *JPSP*. — 混合情绪实验（~10%被试）
11. **Rutledge, R.B. et al.** (2014). A computational and neural model of momentary subjective well-being. *PNAS*. — 统一事件加权，γ≈0.79
12. **Watson, D. & Clark, L.A.** (1988). PANAS. *JPSP*. — PA/NA 双轴模型
13. **Russell, J.A.** (1980). A circumplex model of affect. *JPSP*. — V/A 二维情感坐标系

---

*补充于 2026-05-12*